

Introdução à inferência estatística em alta dimensão

X Encontro Baiano de Estatística (EBEST)

Rodney Fonseca

Departamento de Estatística
Universidade Federal da Bahia

09/06/2026

Introdução

- Métodos com regularização ℓ_1 : combinam seleção de variável e estimação de parâmetros
- Modelo selecionado com validação cruzada e validação realizada em um conjunto teste

- Métodos com regularização ℓ_1 : combinam seleção de variável e estimação de parâmetros
- Modelo selecionado com validação cruzada e validação realizada em um conjunto teste
- **Inferência estatística**: como determinar a significância estatística das variáveis selecionadas?

- Métodos com regularização ℓ_1 : combinam seleção de variável e estimação de parâmetros
- Modelo selecionado com validação cruzada e validação realizada em um conjunto teste
- **Inferência estatística**: como determinar a significância estatística das variáveis selecionadas?
- Métodos usuais (p-valores, intervalos de confiança) necessitam de adaptações em modelos regularizados

- Veremos alguns métodos de inferência em alta dimensão, com foco em **intervalos de confiança**
- Quantificar a incerteza de estimativas obtidas em modelos esparsos e sobre as variáveis selecionadas
- **Fonte:** Hastie et al. (2015, Cap. 6)

O bootstrap

- Seja $T_n = g(X_1, \dots, X_n)$ uma estatística de dados i.i.d. com função de distribuição F
- Obter certas propriedades (viés, variância, etc) de T_n requer conhecer a sua distribuição, algo nem sempre possível

- Seja $T_n = g(X_1, \dots, X_n)$ uma estatística de dados i.i.d. com função de distribuição F
- Obter certas propriedades (viés, variância, etc) de T_n requer conhecer a sua distribuição, algo nem sempre possível
- **Alternativas:**
 - 1 distribuição assintótica de T_n

- Seja $T_n = g(X_1, \dots, X_n)$ uma estatística de dados i.i.d. com função de distribuição F
- Obter certas propriedades (viés, variância, etc) de T_n requer conhecer a sua distribuição, algo nem sempre possível
- **Alternativas:**
 - 1 distribuição assintótica de T_n
 - 2 métodos numéricos para aproximar a distribuição T_n

- Seja $T_n = g(X_1, \dots, X_n)$ uma estatística de dados i.i.d. com função de distribuição F
- Obter certas propriedades (viés, variância, etc) de T_n requer conhecer a sua distribuição, algo nem sempre possível
- **Alternativas:**
 - 1 distribuição assintótica de T_n
 - 2 métodos numéricos para aproximar a distribuição T_n
- **Bootstrap:** Método numérico muito usado para estimar erro padrão e intervalo de confiança

Exemplo: variância de T_n

- Note que $Var(T_n)$ depende da distribuição dos dados F
 - ▶ Se $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ e $T_n = \bar{X}_n$, então $Var(T_n) = \sigma^2/n$, em que $\sigma^2 = \int (x - \mu)^2 dF(x)$ e $\mu = \int x dF(x)$

Exemplo: variância de T_n

- Note que $Var(T_n)$ depende da distribuição dos dados F
 - ▶ Se $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ e $T_n = \bar{X}_n$, então $Var(T_n) = \sigma^2/n$, em que $\sigma^2 = \int (x - \mu)^2 dF(x)$ e $\mu = \int x dF(x)$
- Ideia do **bootstrap não-paramétrico**:
 - 1 Aproximar $Var_F(T_n)$ por $Var_{\hat{F}_n}(T_n)$, em que $\hat{F}_n$ é a função de distribuição empírica dos dados
 - 2 Estimar $Var_{\hat{F}_n}(T_n)$ gerando amostras aleatórias a partir de $\hat{F}_n$

Exemplo: variância de T_n

- Note que $Var(T_n)$ depende da distribuição dos dados F
 - ▶ Se $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ e $T_n = \bar{X}_n$, então $Var(T_n) = \sigma^2/n$, em que $\sigma^2 = \int (x - \mu)^2 dF(x)$ e $\mu = \int x dF(x)$
- Ideia do **bootstrap não-paramétrico**:
 - 1 Aproximar $Var_F(T_n)$ por $Var_{\hat{F}_n}(T_n)$, em que $\hat{F}_n$ é a função de distribuição empírica dos dados
 - 2 Estimar $Var_{\hat{F}_n}(T_n)$ gerando amostras aleatórias a partir de $\hat{F}_n$
- **Vantagem**: estimamos $Var_F(T_n)$ sem precisar deduzir a distribuição de T_n

- A **função de distribuição empírica** é definida como

$$\hat{F}_n(t) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}\{X_i \leq t\},$$

em que $\mathbb{I}(\cdot)$ é uma função indicadora

- A **função de distribuição empírica** é definida como

$$\hat{F}_n(t) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}\{X_i \leq t\},$$

em que $\mathbb{I}(\cdot)$ é uma função indicadora

- $\hat{F}_n$ é uma distribuição uniforme discreta que atribui probabilidade $1/n$ para cada X_i dos dados $X_1, \dots, X_n$

- A **função de distribuição empírica** é definida como

$$\hat{F}_n(t) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}\{X_i \leq t\},$$

em que $\mathbb{I}(\cdot)$ é uma função indicadora

- $\hat{F}_n$ é uma distribuição uniforme discreta que atribui probabilidade $1/n$ para cada X_i dos dados $X_1, \dots, X_n$
- Gerar amostras de $\hat{F}_n$ equivale a sortear valores de $\{X_1, \dots, X_n\}$ **com reposição**

- Ilustração do bootstrap não-paramétrico:

$$\text{Mundo real } F \Rightarrow X_1, \dots, X_n \Rightarrow T_n = g(X_1, \dots, X_n)$$

- Ilustração do bootstrap não-paramétrico:

Mundo real $F \Rightarrow X_1, \dots, X_n \Rightarrow T_n = g(X_1, \dots, X_n)$

Mundo bootstrap $\hat{F}_n \Rightarrow X_1^*, \dots, X_n^* \Rightarrow T_n^* = g(X_1^*, \dots, X_n^*)$

- Ilustração do bootstrap não-paramétrico:

$$\text{Mundo real } F \Rightarrow X_1, \dots, X_n \Rightarrow T_n = g(X_1, \dots, X_n)$$

$$\text{Mundo bootstrap } \hat{F}_n \Rightarrow X_1^*, \dots, X_n^* \Rightarrow T_n^* = g(X_1^*, \dots, X_n^*)$$

- A amostra $X_1^*, \dots, X_n^*$ de $\hat{F}_n$ é obtida sorteando **com reposição** n valores de $\{X_1, \dots, X_n\}$
- Gerando vários T_n^* 's independentes, **podemos estimar a distribuição** de T_n

Erro padrão bootstrap

- Estimar $Var(T_n)$ via bootstrap:
 - 1 Tome uma amostra $X_1^*, \dots, X_n^*$ de $\{X_1, \dots, X_n\}$ com reposição
 - 2 Calcule $T_n^* = g(X_1^*, \dots, X_n^*)$
 - 3 Repita os passos 1 e 2 por B vezes, gerando $T_{n1}^*, \dots, T_{nB}^*$
 - 4 Calcule $V_{\text{boot}} = \frac{1}{B} \sum_{b=1}^B \left(T_{nb}^* - \frac{1}{B} \sum_{k=1}^B T_{nk}^* \right)^2$
- O **erro padrão bootstrap** será $\sqrt{V_{\text{boot}}}$

Intervalo de confiança bootstrap

- Construir um intervalo de $(1 - \alpha)100\%$ de confiança para T_n :
 - 1 Tome uma amostra $X_1^*, \dots, X_n^*$ de $\{X_1, \dots, X_n\}$ com reposição
 - 2 Calcule $T_n^* = g(X_1^*, \dots, X_n^*)$
 - 3 Repita os passos 1 e 2 por B vezes, gerando $T_{n1}^*, \dots, T_{nB}^*$
 - 4 Calcule $C_n = [T_{\alpha/2}^*, T_{1-\alpha/2}^*]$ em que T_γ^* é o quantil $\gamma 100\%$ de $T_{n1}^*, \dots, T_{nB}^*$
- C_n é chamado **IC bootstrap percentil**

- O mesmo princípio pode ser aplicado para estimar outras quantidades de T_n

- O mesmo princípio pode ser aplicado para estimar outras quantidades de T_n
- A **distribuição bootstrap** é usada de forma parecida à distribuição a posteriori na abordagem Bayesiana

- O mesmo princípio pode ser aplicado para estimar outras quantidades de T_n
- A **distribuição bootstrap** é usada de forma parecida à distribuição a posteriori na abordagem Bayesiana
- **Observação:** no caso de regressão, a reamostragem é feita com os pares de resposta & preditor $(y_1, \mathbf{X}_1), \dots, (y_n, \mathbf{X}_n)$, em que $\mathbf{X}_i \in \mathbb{R}^p$ é o vetor de preditores

Estimadores regularizados/penalizados

- Geralmente não conhecemos a distribuição (nem assintótica) de estimadores pontuais $\hat{\beta}$ de modelos regularizados como o lasso

Estimadores regularizados/penalizados

- Geralmente não conhecemos a distribuição (nem assintótica) de estimadores pontuais $\hat{\beta}$ de modelos regularizados como o lasso
- Método bootstrap é útil para estimar a distribuição de $\hat{\beta}$ e **quantificar a incerteza** sobre estimativas regularizadas

Estimadores regularizados/penalizados

- Geralmente não conhecemos a distribuição (nem assintótica) de estimadores pontuais $\hat{\beta}$ de modelos regularizados como o lasso
- Método bootstrap é útil para estimar a distribuição de $\hat{\beta}$ e **quantificar a incerteza** sobre estimativas regularizadas
- Bootstrap também auxilia a estimar a **distribuição da regularização** λ escolhida

Lasso bootstrap

- Seja $\hat{\beta}(\lambda)$ uma estimativa lasso obtida com $\{(y_i, \mathbf{X}_i)\}_{i=1}^n$
 - 1 Tome uma amostra $(y_1^*, \mathbf{X}_1^*), \dots, (y_n^*, \mathbf{X}_n^*)$ sorteando pares de $\{(y_i, \mathbf{X}_i)\}_{i=1}^n$ com reposição
 - 2 Escolha λ^* (via CV, por exemplo) e calcule $\hat{\beta}(\lambda^*)$ usando $\{(y_i^*, \mathbf{X}_i^*)\}_{i=1}^n$
 - 3 Repita os passos 1 e 2 por B vezes, gerando $\lambda_1^*, \dots, \lambda_B^*$ e $\hat{\beta}_1^*, \dots, \hat{\beta}_B^*$
 - 4 Calcule as estimativas bootstrap de interesse

Lasso bootstrap

- Seja $\hat{\beta}(\lambda)$ uma estimativa lasso obtida com $\{(y_i, \mathbf{X}_i)\}_{i=1}^n$
 - 1 Tome uma amostra $(y_1^*, \mathbf{X}_1^*), \dots, (y_n^*, \mathbf{X}_n^*)$ sorteando pares de $\{(y_i, \mathbf{X}_i)\}_{i=1}^n$ com reposição
 - 2 Escolha λ^* (via CV, por exemplo) e calcule $\hat{\beta}(\lambda^*)$ usando $\{(y_i^*, \mathbf{X}_i^*)\}_{i=1}^n$
 - 3 Repita os passos 1 e 2 por B vezes, gerando $\lambda_1^*, \dots, \lambda_B^*$ e $\hat{\beta}_1^*, \dots, \hat{\beta}_B^*$
 - 4 Calcule as estimativas bootstrap de interesse
- **Atenção:** o mesmo procedimento deve ser realizado em cada b -ésima repetição

Exemplo: dados de diabetes

- Dados de $n = 442$ pacientes com uma medida de progresso da diabetes
- As variáveis explicativas são:
 - ▶ X_1 : sexo
 - ▶ X_2 : idade do paciente
 - ▶ X_3 : índice de massa corporal
 - ▶ X_4 : pressão sanguínea média
 - ▶ $X_5, \dots, X_{10}$: medidas sanguíneas
- Todas medidas foram normalizadas para a análise




Figura: Trajetória das estimativas do lasso para diferentes penalizações λ




Figura: EQM estimado via validação cruzada para diferentes λ 's

Tabela: Estimativas de $\beta_1, \dots, \beta_{10}$ pelo lasso com $\lambda = 0.0029$

	Lasso
β_1	0
β_2	-0.0317
β_3	0.3147
β_4	0.1362
β_5	0
β_6	0
β_7	-0.0940
β_8	0
β_9	0.2762
β_{10}	0

- Dados de $n = 442$ pacientes com uma medida de progresso da diabetes, contendo $p = 10$ variáveis explicativas
- Análise anterior com o lasso selecionou X_2, X_3, X_4, X_7 e X_9
- Agora aplicamos bootstrap com $B = 300$ réplicas




Figura: Histograma das estimativas bootstrap de β_1^* , β_2^* e λ^*





Figura: Trajetórias das estimativas bootstrap de β_1^* e β_2^* vs. λ^*




Figura: Boxplots das estimativas bootstrap




Figura: Proporção de estimativas bootstrap que foram zero para cada parâmetro

Tabela: Estimativas de $\beta_1, \dots, \beta_{10}$ usando o Lasso com λ_{CV} , erro padrão bootstrap (EP) e intervalo de 95% de confiança bootstrap (IC)

	Lasso	EP	IC 95%
β_1	0	0.00	[0.00, 0.00]
β_2	-0.0317	0.03	[-0.10, 0.00]
β_3	0.3147	0.04	[0.22, 0.39]
β_4	0.1362	0.04	[0.04, 0.20]
β_5	0	0.01	[-0.04, 0.00]
β_6	0	0.01	[-0.04, 0.00]
β_7	-0.0940	0.04	[-0.17, -0.00]
β_8	0	0.01	[0.00, 0.03]
β_9	0.2762	0.05	[0.19, 0.35]
β_{10}	0	0.02	[0.00, 0.07]

Lasso deviesado

- **Distribuição assintótica** do estimador de mínimos quadrados no modelo linear:

$$\hat{\beta}_{mqo} \sim N(\beta^*, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}), \quad n > p, \quad n \text{ grande},$$

em que β^* é o vetor de coeficientes de regressão verdadeiros

- **Distribuição assintótica** do estimador de mínimos quadrados no modelo linear:

$$\hat{\beta}_{mqo} \sim N(\beta^*, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}), \quad n > p, \quad n \text{ grande},$$

em que β^* é o vetor de coeficientes de regressão verdadeiros

- **Inferência aproximada** usando a distribuição assintótica
 - ▶ IC para β_j^* : $\hat{\beta}_j \pm z_{1-\alpha/2} \cdot \sqrt{v_j} \hat{\sigma}$, em que v_j é o j -ésimo elemento da diagonal de $(\mathbf{X}^\top \mathbf{X})^{-1}$

- **Distribuição assintótica** do estimador de mínimos quadrados no modelo linear:

$$\hat{\beta}_{mqo} \sim N(\beta^*, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}), \quad n > p, \quad n \text{ grande},$$

em que β^* é o vetor de coeficientes de regressão verdadeiros

- **Inferência aproximada** usando a distribuição assintótica
 - ▶ IC para β_j^* : $\hat{\beta}_j \pm z_{1-\alpha/2} \cdot \sqrt{v_j} \hat{\sigma}$, em que v_j é o j -ésimo elemento da diagonal de $(\mathbf{X}^\top \mathbf{X})^{-1}$
 - ▶ Teste t para $H_0 : \beta_j^* = 0$ vs. $H_1 : \beta_j^* \neq 0$: $t_j = \frac{\hat{\beta}_j}{\sqrt{v_j} \hat{\sigma}}$, rejeitando H_0 ao nível α se $|t_j| > t_{n-p, 1-\alpha/2}$

- Problema com **estimador lasso** $\hat{\beta}_\lambda$: **viesado** e não conhecemos a sua distribuição para grandes amostras

- Problema com **estimador lasso** $\hat{\beta}_\lambda$: **viesado** e não conhecemos a sua distribuição para grandes amostras
- O **lasso deviesado** consiste em aplicar uma correção de viés a $\hat{\beta}_\lambda$ que permita deduzir a sua distribuição assintótica

- Problema com **estimador lasso** $\hat{\beta}_\lambda$: **viesado** e não conhecemos a sua distribuição para grandes amostras
- O **lasso deviesado** consiste em aplicar uma correção de viés a $\hat{\beta}_\lambda$ que permita deduzir a sua distribuição assintótica
- Tal distribuição pode ser utilizada para fazer inferência aproximada para β^*

- Considere o **modelo linear normal**

$$\mathbf{y} = \mathbf{X}\beta^* + \epsilon, \quad \epsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_p)$$

- Se $n > p$, o estimador de MQO pode ser escrito como

$$\hat{\beta}_{mqo} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \beta^* + \frac{1}{\sqrt{n}} \left(\frac{\mathbf{X}^\top \mathbf{X}}{n} \right)^{-1} \frac{\mathbf{X}^\top}{\sqrt{n}} \epsilon$$

- Considere o **modelo linear normal**

$$\mathbf{y} = \mathbf{X}\beta^* + \epsilon, \quad \epsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_p)$$

- Se $n > p$, o estimador de MQO pode ser escrito como

$$\hat{\beta}_{mqo} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \beta^* + \underbrace{\frac{1}{\sqrt{n}} \left(\frac{\mathbf{X}^\top \mathbf{X}}{n} \right)^{-1} \frac{\mathbf{X}^\top}{\sqrt{n}} \epsilon}_{N(\mathbf{0}, \sigma^2 (\mathbf{X}^\top \mathbf{X} / n)^{-1}), \text{ dado } \mathbf{X}}$$

- Considere o **modelo linear normal**

$$\mathbf{y} = \mathbf{X}\beta^* + \epsilon, \quad \epsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_p)$$

- Se $n > p$, o estimador de MQO pode ser escrito como

$$\hat{\beta}_{mqo} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \beta^* + \underbrace{\frac{1}{\sqrt{n}} \left(\frac{\mathbf{X}^\top \mathbf{X}}{n} \right)^{-1} \frac{\mathbf{X}^\top}{\sqrt{n}} \epsilon}_{N(\mathbf{0}, \sigma^2 (\mathbf{X}^\top \mathbf{X}/n)^{-1}), \text{ dado } \mathbf{X}}$$

- Logo, $\hat{\beta}_{mqo} | \mathbf{X} \sim N(\beta^*, \sigma^2 (\mathbf{X}^\top \mathbf{X}/n)^{-1})$

- O **lasso deviesado** é dado por

$$\hat{\beta}^d = \hat{\beta}_\lambda + \frac{1}{n} \hat{\Theta} \mathbf{X}^\top (\mathbf{y} - \mathbf{X} \hat{\beta}_\lambda),$$

em que $\hat{\Theta}$ é uma aproximação da inversa de $\hat{\Sigma} = \frac{1}{n} \mathbf{X}^\top \mathbf{X}$

- O **lasso deviesado** é dado por

$$\hat{\beta}^d = \hat{\beta}_\lambda + \frac{1}{n} \hat{\Theta} \mathbf{X}^\top (\mathbf{y} - \mathbf{X} \hat{\beta}_\lambda),$$

em que $\hat{\Theta}$ é uma aproximação da inversa de $\hat{\Sigma} = \frac{1}{n} \mathbf{X}^\top \mathbf{X}$

- Podemos reescrever $\hat{\beta}^d$ como

$$\hat{\beta}^d = \beta^* + \frac{1}{\sqrt{n}} \hat{\Theta} \frac{\mathbf{X}^\top}{\sqrt{n}} \epsilon + (I_p - \hat{\Theta} \hat{\Sigma})(\hat{\beta}_\lambda - \beta^*)$$

- O **lasso deviesado** é dado por

$$\hat{\beta}^d = \hat{\beta}_\lambda + \frac{1}{n} \hat{\Theta} \mathbf{X}^\top (\mathbf{y} - \mathbf{X} \hat{\beta}_\lambda)$$

em que $\hat{\Theta}$ é uma aproximação da inversa de $\hat{\Sigma} = \frac{1}{n} \mathbf{X}^\top \mathbf{X}$

- Podemos reescrever $\hat{\beta}^d$ como

$$\hat{\beta}^d = \beta^* + \frac{1}{\sqrt{n}} \underbrace{\hat{\Theta} \frac{\mathbf{X}^\top}{\sqrt{n}} \epsilon}_{N(\mathbf{0}, \sigma^2 \hat{\Theta} \hat{\Sigma} \hat{\Theta}^\top), \text{ dado } \mathbf{X}} + \underbrace{(I_p - \hat{\Theta} \hat{\Sigma})(\hat{\beta}_\lambda - \beta^*)}_{\hat{\Delta}}$$

- O **lasso deviesado** é dado por

$$\hat{\beta}^d = \hat{\beta}_\lambda + \frac{1}{n} \hat{\Theta} \mathbf{X}^\top (\mathbf{y} - \mathbf{X} \hat{\beta}_\lambda)$$

em que $\hat{\Theta}$ é uma aproximação da inversa de $\hat{\Sigma} = \frac{1}{n} \mathbf{X}^\top \mathbf{X}$

- Podemos reescrever $\hat{\beta}^d$ como

$$\hat{\beta}^d = \beta^* + \underbrace{\frac{1}{\sqrt{n}} \hat{\Theta} \frac{\mathbf{X}^\top}{\sqrt{n}} \epsilon}_{N(\mathbf{0}, \sigma^2 \hat{\Theta} \hat{\Sigma} \hat{\Theta}^\top), \text{ dado } \mathbf{X}} + \underbrace{(I_p - \hat{\Theta} \hat{\Sigma}) (\hat{\beta}_\lambda - \beta^*)}_{\hat{\Delta}}$$

- Se $\hat{\Delta} \approx \mathbf{0}$, então $\hat{\beta}^d$ é aproximadamente $N(\beta^*, \sigma^2 \hat{\Theta} \hat{\Sigma} \hat{\Theta}^\top)$

- Se $n > p$, tomando $\hat{\Theta} = \hat{\Sigma}$ obtemos $\hat{\beta}^d = \hat{\beta}_{mqo}$
- **Desafio quando $p > n$:** obter $\hat{\Theta}$ tal que o viés remanescente de $\hat{\beta}^d$ seja pequeno, ou seja,

$$\|\hat{\Delta}\| = \|(I_p - \hat{\Theta}\hat{\Sigma})(\hat{\beta}_\lambda - \beta^*)\| \approx 0$$

- Se $n > p$, tomando $\hat{\Theta} = \hat{\Sigma}$ obtemos $\hat{\beta}^d = \hat{\beta}_{mqo}$
- **Desafio quando $p > n$:** obter $\hat{\Theta}$ tal que o viés remanescente de $\hat{\beta}^d$ seja pequeno, ou seja,

$$\|\hat{\Delta}\| = \|(I_p - \hat{\Theta}\hat{\Sigma})(\hat{\beta}_\lambda - \beta^*)\| \approx 0$$

- Possíveis abordagens:
 - ▶ Calcular $\hat{\Theta}$ tal que $\|\hat{\Sigma}\hat{\Theta} - I_p\|$ seja pequeno (Javanmard and Montanari, 2014b)

- Se $n > p$, tomando $\hat{\Theta} = \hat{\Sigma}$ obtemos $\hat{\beta}^d = \hat{\beta}_{mqo}$
- **Desafio quando $p > n$:** obter $\hat{\Theta}$ tal que o viés remanescente de $\hat{\beta}^d$ seja pequeno, ou seja,

$$\|\hat{\Delta}\| = \|(I_p - \hat{\Theta}\hat{\Sigma})(\hat{\beta}_\lambda - \beta^*)\| \approx 0$$

- Possíveis abordagens:
 - ▶ Calcular $\hat{\Theta}$ tal que $\|\hat{\Sigma}\hat{\Theta} - I_p\|$ seja pequeno (Javanmard and Montanari, 2014b)
 - ▶ Calcular $\hat{\Theta}$ como uma **estimativa esparsa da matriz de precisão** Σ^{-1} (van de Geer et al., 2014)

Exemplo: dados de diabetes

- Dados de $n = 442$ pacientes com uma medida de progresso da diabetes, contendo 10 variáveis explicativas
- Ajustaremos um modelo incluindo termos quadráticos e interações, com total de $p = 64$ covariáveis
- Lista das covariáveis: sexo (X_1), idade (X_2), IMC (X_3), pressão (X_4), medidas sanguíneas ($X_5, \dots, X_{10}$), termos quadráticos e interações




Figura: Trajetória das estimativas lasso do modelo quadrático para diferentes penalizações λ




Figura: EQM estimado via validação cruzada do modelo quadrático para diferentes λ 's




Figura: Estimativas do modelo quadrático utilizando lasso com penalização $\lambda_{CV} = 0.0018$

Tabela: Dez maiores estimativas (em valor absoluto) do modelo quadrático usando lasso e $\lambda_{CV} = 0.0018$

Parâmetro	Lasso
β_4	0.31
β_{10}	0.29
β_5	0.16
β_8	-0.12
β_3	-0.07
β_{21}	0.07
β_{38}	0.05
β_{20}	0.04
β_{13}	0.02
β_{23}	0.02




Figura: Estimativas do modelo quadrático utilizando lasso desviado com IC's de 95% de confiança




Figura: Estimativas lasso que são diferentes de zero mas cujo IC de 95% obtido com lasso deviesado contém zero




Figura: Valores-p para as estimativas obtidas via lasso deviesado. Linha vermelha marca o nível $\alpha = 0.05$

Tabela: Dez maiores estimativas do modelo quadrático usando lasso e $\lambda_{CV} = 0.0018$, estimativas correspondentes pelo lasso deviesado e IC's de 95%

Parâmetro	Lasso	Lasso dev.	IC
β_4	0.31	0.19	(0.10, 0.28)
β_{10}	0.29	0.03	(-0.06, 0.12)
β_5	0.16	-0.01	(-0.11, 0.09)
β_8	-0.12	0.03	(-0.07, 0.14)
β_3	-0.07	0.32	(0.22, 0.42)
β_{21}	0.07	-0.01	(-0.11, 0.08)
β_{38}	0.05	-0.00	(-0.10, 0.10)
β_{20}	0.04	0.10	(0.01, 0.18)
β_{13}	0.02	-0.00	(-0.09, 0.08)
β_{23}	0.02	0.00	(-0.10, 0.11)

Observações

- Conseguimos fazer inferência com o **lasso deviesado**, mas as **estimativas pontuais não são esparsas**

Observações

- Conseguimos fazer inferência com o **lasso deviesado**, mas as **estimativas pontuais não são esparsas**
- Também existe **estimadores deviesados para lasso MLG**, caso em que a correção de viés envolve outra função objetivo $\mathcal{L}(\beta)$ e sua matriz Hessiana

Observações

- Conseguimos fazer inferência com o **lasso deviesado**, mas as **estimativas pontuais não são esparsas**
- Também existe **estimadores deviesados para lasso MLG**, caso em que a correção de viés envolve outra função objetivo $\mathcal{L}(\beta)$ e sua matriz Hessiana
- Testes de hipóteses múltiplos necessitam ajustes no nível de significância (e.g., **Bonferroni**) ou correções que controlem a taxa de rejeições falsas (e.g., **FDR**)

Referências

- T. Hastie, R. Tibshirani, and M. Wainwright. *Statistical Learning with Sparsity: The Lasso and Generalizations*. CRC Press, Boca Raton, 2015.
- A. Javanmard and A. Montanari. Confidence intervals and hypothesis testing for high-dimensional regression. *The Journal of Machine Learning Research*, 15(1): 2869–2909, 2014b.
- S. van de Geer, P. Bühlmann, Y. Ritov, and R. Dezeure. On asymptotically optimal confidence regions and tests for high-dimensional models. *The Annals of Statistics*, 42(3):1166–1202, 2014.